

MedSync

Limpieza de Datos

Fecha: 6 de abril de 2026

1. Introducción

Este proyecto utiliza la API pública de NCBI E-utilities para obtener artículos científicos en tendencia desde PubMed y aplicar técnicas de exploración y limpieza de datos con la librería Pandas.

La API de PubMed expone dos endpoints principales que se utilizan en este proyecto:

- **esearch.fcgi**: Busca artículos y devuelve una lista de identificadores (PMIDs). En nuestro caso, usamos el filtro ``trending[sb]`` que devuelve los 1,000 artículos con mayor actividad reciente (vistas, citas, menciones), sin necesidad de especificar una palabra clave.
- **efetch.fcgi**: Recibe los PMIDs y devuelve los datos completos de cada artículo en formato XML, incluyendo título, autores, abstract, revista, DOI, entre otros.

Datos disponibles vs. datos seleccionados

La API de efetch devuelve **16 campos** por cada artículo:

#	Campo	Descripción	Tipo de Dato Sugerido
1	pmid	Identificador único de PubMed	Numérico (ID)
2	título	Título original del artículo	Texto
3	autores	Lista de autores en formato: Apellido Nombre	Texto / Lista
4	revista	Nombre completo de la revista académica	Texto

5	revista_abrev	Abreviatura oficial (ISO) de la revista	Texto
6	año_pub	Año de publicación	Número (YYYY)
7	mes_pub	Mes de publicación	Texto / Número
8	volumen	Volumen de la revista	Alfanumérico
9	numero	Número del ejemplar (Issue)	Alfanumérico
10	paginas	Rango de páginas (p. ej., 100-115)	Texto
11	doi	<i>Digital Object Identifier</i> (Enlace permanente)	Texto (URI)
12	abstract	Texto completo del resumen o síntesis	Texto (Largo)
13	keywords	Palabras clave asignadas por los autores	Texto / Tags
14	mesh_terms	Términos controlados (MeSH) asignados por NCBI	Texto / Lista

15	tipo_publicacion	Categoría (Journal Article, Review, Case Report, etc.)	Texto / Categoría
16	idioma	Idioma en el que está escrito el artículo	Texto (ISO Code)

De estos 16, seleccionamos **10 columnas** para trabajar, descartando las que aportan información redundante o de poco valor analítico:

Campo	Razón de Descarte	Impacto en el Modelo/Análisis
pmid	Es un identificador interno de la base de datos sin valor semántico.	Se elimina para evitar ruido estadístico (no es una variable predictiva).
revista_abrev	Información duplicada; el nombre completo (revista) ya está presente.	Reduce la redundancia y optimiza el tamaño del dataset.
volumen	Inconsistencia de datos: los artículos <i>trending</i> suelen ser recientes y no tienen volumen.	Evita el sesgo por valores nulos (nulls) en publicaciones nuevas.
numero	Inconsistencia de datos similar al volumen.	Limpieza de datos por falta de completitud en artículos de publicación rápida.

paginas	Datos faltantes en versiones "Ahead of Print" o digitales.	Elimina variables con alta variabilidad o ausencia de información técnica.
idioma	Constante: el 100% de la muestra está en inglés.	Al no haber varianza, el campo no aporta información para comparar o categorizar.

Las **10 columnas finales** son: ``doi``, ``titulo``, ``anio_pub``, ``mes_pub``, ``abstract``, ``mesh_terms``, ``autores``, ``revista``, ``keywords``, ``tipo_publicacion``.

2. Descubrimiento

2.1 Comportamiento de los datos de tendencia

Al usar el filtro ``trending[sb]``, los artículos devueltos son aquellos con mayor actividad reciente en PubMed. Esto tiene implicaciones directas en los datos:

- **Las fechas son casi idénticas:** El 96% de los artículos tienen fecha de abril 2026, ya que los artículos en tendencia son publicaciones muy recientes. Los pocos con fechas futuras (2027, 2028) corresponden a artículos publicados como "ahead of print" en revistas que ya les asignaron un volumen futuro.
- **Un solo idioma:** Todos los artículos trending están en inglés (``eng``), lo cual confirma la decisión de descartar la columna ``idioma`` ya que no tiene variabilidad.

2.2 Valores nulos (NaN)

Los valores nulos no están distribuidos uniformemente. Se concentran en dos columnas:

Columna	Nulos	Porcentaje	Explicación

mesh_terms	36	72%	Los términos MeSH son asignados manualmente por indexadores de NCBI. Este proceso toma semanas o meses después de la publicación. Como los artículos trending son muy recientes, la mayoría aún no han sido indexados.
keywords	24	48%	Las keywords dependen de que los autores las incluyan al momento de enviar el artículo. No todas las revistas las requieren, por lo que casi la mitad de los artículos no las tienen.
titulo	1	2%	Caso atípico, probablemente un artículo con título en formato no estándar.
mes_pub	1	2%	Algunas revistas solo publican el año sin especificar mes.

Las demás columnas (`doi`, `abstract`, `autores`, `revista`, `año\_pub`, `tipo\_publicacion`) tienen 0% de nulos, lo cual indica que son campos obligatorios en el sistema de PubMed.

2.3 Duplicados

No se encontraron filas duplicadas en el dataset (0 de 50), lo cual es esperado ya que cada artículo tiene un DOI único.

2.4 Distribución por revista

Los artículos trending provienen de revistas de alto impacto: Nature (7), The New England Journal of Medicine (3), PNAS (2), Science (2), Blood (2), JAMA (2), entre otras. Esto confirma que el algoritmo de trending de PubMed favorece publicaciones en revistas con mayor visibilidad.

2.5 Tipos de publicación

La mayoría son "Journal Article" (78%), seguidos de "Journal Article; Review" (12%) y algunos ensayos clínicos aleatorizados. Esto refleja que los artículos con resultados originales tienden a generar más actividad que las revisiones.

2.4 Estrategia de limpieza

Para la limpieza de datos se aplican tres técnicas:

1. **dropna()**: Elimina filas con cualquier valor nulo. En este dataset reduce de 50 a solo 7 filas, lo cual demuestra que no es una estrategia viable cuando los nulos se concentran en pocas columnas.
2. **drop_duplicates()**: No tiene efecto ya que no hay duplicados.
3. **fillna()**: Se rellenan los campos de texto nulos con "No disponible", que es la estrategia más adecuada para este dataset ya que preserva todas las filas sin introducir datos falsos.